

DBCLS BioHackathon 2026 レポート

ゼニゴケゲノムデータベース MarpolBase の知識ベース化と、AI を用いた DDBJ 登録支援ツール

谷澤 靖洋 (Yasuhiro Tanizawa)¹、藤澤 貴智 (Takatomo Fujisawa)¹

¹ 国立遺伝学研究所 生命情報・DDBJ センター

DBCLS BioHackathon 2026 (BH26JP) / 2026年9月13-19日、愛媛県松山市・2026年9月18日

リポジトリ: <https://github.com/biohackathon-japan/BH26-marpolbase-ddbj>

本稿は *BioHackrXiv* 提出版 `paper.md` の日本語版である。

はじめに

本プロジェクトでは、ゆるやかに関連する二つの目標に取り組んだ。

一つめは、ゼニゴケ (*Marchantia polymorpha*; Bowman et al., 2017) のゲノムデータベース **MarpolBase** (Tanizawa et al., 2025) を知識ベース化することである。具体的には、遺伝子・発現・文献のデータを RDF として公開し、SPARQL エンドポイントを通じて提供し、さらに Model Context Protocol (MCP) サーバを介して AI エージェントから利用できるようにした。

二つめは、**DDBJ への登録コスト**を下げることである。DDBJ 登録ファイルの作成は依然として手作業に頼る部分が多い。ここで報告する二つのサイドプロジェクト — DFAST-Agent と MARKit — は、この問題に二つの方向から取り組むものである。前者は対話を通じて登録ファイルを組み立てる エージェントであり、後者は登録ファイルを機械的に生成・点検するツールである。

本ハッカソンで作成したリソースとツールを表 1 に示す。

表 1: BioHackathon 2026 で開発・拡張したリソースとツール

名称	URL	説明
MarpolBase RDF	https://marchantia.info/rdf/	MarpolBase の遺伝子・発現・文献データの RDF 配布
MarpolBase SPARQL エンドポイント	https://marchantia.info/sparql	公開エンドポイント。TogoMCP と RDF Portal に登録済み
MarpolBase MCP サーバ	https://marchantia.info/mcp	遺伝子・発現・共発現・文献への型付きアクセスを提供する 14 ツール
dfast-agent-p	https://github.com/nigyta/dfast-agent-p	DFAST API を用いて原核生物ゲノムの DDBJ 登録ファイルを作成するエージェント
DFAST-Agent (真核生物用)	開発中	GFF から DDBJ 登録ファイルへの変換エージェント。local LLM を用いた Web インターフェースも開発中
MARKit	https://ggs-staging.ddbj.nig.ac.jp/tools/markit	系統マーカー配列の登録支援ツール。コンテナ <code>nigyta/markit:latest</code>

MarpolBase の RDF 化と MCP サーバ

公開したもの


MarpolBase が提供する遺伝子情報・発現情報・文献情報を RDF に変換して公開した。SPARQL エンドポイントは TogoMCP と RDF Portal の双方に登録したため、国内で整備されている データベース横断のクエリ環境から MarpolBase に到達できるようになった。さらにエンドポイントの 上に 14 個のツールを持つ MCP サーバを構築し、LLM エージェントが SPARQL を自分で書かずに このリソースを検索できるようにした。

ツールは大きく五つに分かれる。遺伝子の取得と検索、発現プロファイルと条件間比較、共発現 ネットワーク、キュレーション済みの遺伝子-文献リンク、統制語彙の解決である。型付きツールで 足りない場合に備えて `run_sparql` と `describe_schema` も用意し、エージェントが生の SPARQL に フォールバックできるようにしてある。

使用例


自然言語のプロンプトのみで駆動する二つの解析でサーバを検証した。

一つめ (図 1) では、「MpBNB 遺伝子が高発現している条件を教えて」というプロンプトに対し、MarpolBase の全 161 条件における `MpBNB` の平均 TPM を、条件属性 (組織・系統・ステージ・性・変異体・処理・感染) とともに取得して回答した。この遺伝子は造精器で 27.8 TPM に達する 一方、葉状体・無性芽・胞子ではほぼゼロである。発現値がサンプル ID ではなく条件メタデータを 伴っているため、エージェントがこのようにまとめて報告できる。



MCP サーバを介して単一の自然言語プロンプトから取得した、MarpolBase 全 161 条件における *MpBNB* の発現。左: 平均 TPM 上位 14 条件を器官種別で色分けしたもの。右: 同じ値を組織ごとにまとめたもの。

二つめ (図 2) では、塩ストレス下におけるビスビベンジル合成経路を追跡した。発現値は MarpolBase から取得し、代謝経路の文脈 — 化合物 ID、反応、酵素の参照 — は TogoMCP を介して 外部リソース から取得した。律速となる PKS/CHS ステップと、共通のフェニルプロパノイド入口は ともに塩誘導性であり、しかもどのステップでも誘導はパラログ選択的であった。



塩ストレス下のビスビベンジル経路。(a) 各ステップを、そのステップで発現しているパラログのうち最も強く誘導されたものの値で色分けした経路図。(b) 100 mM NaCl 時系列における個々の遺伝子の log₂ fold change をステップごとにまとめたもの。

MarpolBase と TogoMCP それぞれの役割

この二つの解析を通じて、種特異的リソースとデータベース横断ハブの役割分担が具体的に見えた (表 2)。

MarpolBase にしかできないのは、161 条件の実測発現量、共発現ネットワーク (PCC / HRR / MR)、DESeq2 による 2 条件間の差次発現、evidence と role を付してキュレーションされた遺伝子-文献 リンク、そして PECO・PO ID つきの統制語彙の解決である。加えて、独自の KEGG Orthology 付与を持つ — `mpo:hasKEGG` で 6,563 遺伝子。この点は実務上重要だった。ゼニゴケは KEGG GENES に 存在しないため、図 2 の酵素ノードを着色できたのは、MarpolBase が自前で KO 番号を付与して いるからに他ならない。

TogoMCP にしかできないのは、119 データベース間の ID 変換 (TogoID; Ikeda et al., 2022)、生物種 横断の汎用参照 (UniProt、PDB、Reactome、Rhea、ChEMBL、MeSH) の検索、NCBI E-utilities 経 由での SRA・GEO・PubMed へのアクセス、そして複数エンドポイントを選択しての SPARQL 発行で ある。

表 2: 両者が重なる部分と、その質の違い

機能	MarpolBase	TogoMCP
SPARQL	自前グラフ 1 つ (GRAPH の明示が必須)	複数エンドポイントを選択可
文献	ゼニゴケ論文と遺伝子の紐付け (evidence/role 付き)	PubMed / MeSH の汎用検索
化合物	扱わない	ChEBI / Rhea / PubChem の ID 変換
遺伝子発現	161 条件の実測値	持たない

両者は遺伝子 ID では繋がらない

本プロジェクトで最も有用だった否定的な結果がこれである。TogoID にゼニゴケの遺伝子 データセッ トは無く、MarpolBase の `get_gene` は UniProt アクセションを返さない。したがって `Mp3g23300` を ID 変換で直接 TogoMCP 側へ渡す経路は存在しない。あわせて、`pfam → uniprot` は TogoID の経路として存在しない (404) 一方、`rhea ↔ chebi`、`chebi ↔ pubchem_compound`、`uniprot ↔ rhea`、`uniprot ↔ pdb`、`go ↔ uniprot` は存在する ことを確認した。

両者が実際に会うのは**共通語彙のレベル**である。

1. KO 番号 — 図 2 の二層マップを成立させた接点。
2. GO / Pfam — MarpolBase が付与し、TogoMCP 側で参照できる。
3. 化合物 ID (ChEBI / PubChem) — メタボロームデータとの接点。

代わりに UniProt を経由すると、タンパク質名と生物種による検索になるため、MpPAL1~10 のよう な パラログ群では多対多となり信頼できない。

実務上の指針としては次のようになる。ゼニゴケの測定値・条件・共発現・キュレーション文献を知りたいときは MarpolBase を使う。その結果を構造・反応・化合物・他種のオーソログ・配列 アーカイブへ広げたいときは TogoMCP を使う。そして両者の橋渡しは、遺伝子 ID ではなく KO・GO・化合物 ID で行う。

サイドプロジェクト: DDBJ 登録支援ツール DFAST-Agent

DFAST-Agent は、AI エージェントによる DDBJ 登録ファイル作成支援ツールである。登録のための手順や converter を MCP サーバ・スキル・ツールとしてエージェントに提供する。エージェントは DDBJ ユーザー向けの認証付きオブジェクトストレージ **Kura** 上のファイルを参照・操作し、登録に必要なメタデータはユーザーとの対話を通じて収集する。

原核生物用ツール。 原核生物ゲノム用の DFAST API (Tanizawa et al., 2018) を用いて、Kura 上のファイルを DDBJ 登録 ファイルに変換した。ターミナル上での対話的な操作により、登録ファイルの作成に成功している (<https://github.com/nigya/dfast-agent-p>)。

真核生物用ツール。 GFF ファイルから DDBJ 登録ファイルへの変換を実装した。ターミナル上での エージェントとの対話により、必要なメタデータ情報の収集と登録用ファイルへの変換に成功した。また AI エージェントを利用しないユーザーのために、遺伝研スパコン上で動く local LLM を バックエンドとする Web インターフェースを開発し、Kura 上でのファイル操作による登録ファイル 作成を目指した。local LLM を使ったエージェントのチューニングが難しく、この構成でのファイル 変換は成功しなかったが、Kura の利用ノウハウを得ることができた。開発は継続中である。

サイドプロジェクト: 系統マーカー登録用ツール MARKit

背景

COI、16S、ITS などのバーコード配列の登録は、1 提出に数百～数千エントリが含まれる一方、アノテーションは提出者の手作業に頼っている。そのため、座標のずれ、翻訳できない CDS、申告 学名と配列の不一致が登録後に見つかることがある。**MARKit** (Marker Annotation and Registration Kit) は、FASTA と最小限のメタデータから DDBJ MSS 形式の登録ファイルを機械的に 組み立て、提出前に点検するツールである。

処理の流れは、マーカー判定 → 領域決定 → 構造検査 → 学名整合 → 登録ファイル生成 → レポート である。

特徴

- ・ **マーカーを申告に頼らず判定する。** 全モデル (HMM / CM) を当ててエントリごとに決めるため、1 提出にマーカーが混在していても分けて処理し、最後に 1 つの登録ファイルへ合流させる。対応マーカーは 22 種。

- **分類群に応じて遺伝暗号表を選ぶ。** ミトコンドリアの暗号表は分類群ごとに異なるため、申告 学名から分類群を引いたうえで読み枠を評価する。
- **登録できない形を生成の段階で回避する。** 翻訳できない読み枠を CDS にしない、逆鎖は plus 鎖に揃えて座標を移す、など。
- **学名整合。** 参照 DB と配列を距離ベースで照合し、科ごとに校正した閾値で裁定する。申告 学名が無い場合も候補を出すので、種名確定の材料になる。
- **メタデータが揃う前に解析できる。** FASTA だけで解析を実行し、後から登録ファイルを作れる。
- **解析結果を見てエントリ単位に指示できる。** 「登録から外す」「CDS / rRNA ではなく misc_feature / misc_RNA として登録する」を選択できる。
- **実登録データで検証している。** 実際に登録された提出 91 件・約 1 万エントリについて、生成 結果を実登録の .ann と突き合わせ、機能追加のたびに検証している。
- **コンテナで配布。** 実行環境・参照データ・コードを同梱 (Apptainer 657 MB / OCI 4.7 GB、nigyt/markit:latest として公開)。

Web インターフェースの開発

利用者を広げるため、既存の DDBJ Gene/Genome Submission (GGS) ツールに Web インターフェースとして組み込んだ (図 3、図 4)。MARKit 本体をコンテナとして呼び出す構成で、解析ロジックはコマンドライン版と同一である。画面は INPUT / ANALYSIS / BIOLOGICAL SOURCE / COMMON / BUILD & VALIDATE の 5 つからなり、複数の FASTA をそれぞれ異なるマーカー設定で解析できる。画面は日英併記で、アップロードはすべてサーバ側で検証している。

MARKit: Marker Annotation and Registration Kit

Submits barcode sequences of phylogenetic markers (COI / ITS / 16S and others).
It decides each entry's marker and feature boundaries from the sequence itself, checks the declared organism name against a reference database, and writes the DDBJ registration files.
Several FASTA files can be submitted with their own marker settings and are merged into a single submission.

You are not logged in. The job is deleted after 24 hours and does not appear in your history. Keep this page's URL (it carries the job_id) to come back to the same job, and download the registration files you build. Submitting requires a login.

1. INPUT

2. ANALYSIS

3. BIOLOGICAL SOURCE

4. COMMON

5. BUILD & VALIDATE

One set = one FASTA plus one marker setting. Several sets are merged into a single submission (one .ann / .fasta at the end). Entry names must therefore be unique across all sets; duplicates are rejected here.

Set 1

20251225test_COXI.fasta

Marker

auto

+ Add a set

Metadata (optional, one per job)

You can hand over common.json and the sample metadata TSV here as well. The first column of the TSV must match the ID in the FASTA header (everything up to the first space). When both files are present and complete, the analysis and the registration files are built in one go. You can also supply them later on the COMMON and BIOLOGICAL SOURCE tabs.

Choose common.json

Choose sample TSV

Run analysis

MARKit Web インターフェースの INPUT 画面。FASTA ファイルごとにマーカー設定を指定する (auto にすると MARKit が判定する)。common.json とサンプルメタデータ TSV はここでも後の画面でも渡せる。

11 entries

BLOCKED 0

OK 0

REVIEW 11

Markers: COI 11

BLOCKED entries are left out of the registration files (they stay in this table). REVIEW entries need a human check.

Looking at the analysis, you can withdraw an entry from the submission or register it as misc_feature / misc_RNA instead of CDS / rRNA. MARKit rebuilds the registration files; it also decides whether a demoted entry becomes misc_feature or misc_RNA. A note goes into /note on the demoted feature.

BLOCKED

REVIEW

OK

entry	marker	status	organism	verdict	action	location	codon_start	query_coverage	alerts	notes
AB491414_Echinococcus	COI	REVIEW		UNVERIFIABLE	REVIEW	<1..>789	1	0.99		three_prime_partial
AB688152_Phytophthora	COI	REVIEW		UNVERIFIABLE	REVIEW	<1..>672	1	0.99		three_prime_partial
AB948168_Skeletonema	COI	REVIEW		UNVERIFIABLE	REVIEW	<1..>997	2	0.99		three_prime_partial
HQ860420_Bostaurus	COI	REVIEW		UNVERIFIABLE	REVIEW	<1..>658	2	0.99		three_prime_partial
KJ918252_3-terminal-partial	COI	REVIEW		UNVERIFIABLE	REVIEW	25..>1490	1	0.90		three_prime_partial;start_re
KJ918330_start-end_with_UTR	COI	REVIEW		UNVERIFIABLE	REVIEW	25..1572	1	0.57		start_refined_by_hmm;mod
LC798357_forward_CDS	COI	REVIEW		UNVERIFIABLE	REVIEW	<1..>658	2	0.99		three_prime_partial
LC798358_complement_CDS	COI	REVIEW		UNVERIFIABLE	REVIEW	complement(<1..>658)	2	0.99	revcompl	three_prime_partial
LC798359_misc_feature	COI	REVIEW		UNVERIFIABLE	REVIEW	<1..>349	2	0.51	cdsstopp	orf_selected_by_hmm;orf_t
LC798360_forward_CDS	COI	REVIEW		UNVERIFIABLE	REVIEW	<1..>658	2	0.99		three_prime_partial
MW361241_3UTR	COI	REVIEW		UNVERIFIABLE	REVIEW	<1..1532	3	0.51		model_exhausted

Save registration choices

Chosen: 0 not registered / 0 demoted

MARKit Web インターフェースのエントリ単位の解析表。各エントリについて判定されたマーカー、ステータス、フィーチャー座標、codon start、query coverage、アラートが表示され、ここから登録の取り下げや misc_feature / misc_RNA への変更を指示できる。

現状

コマンドライン版は実運用で使える状態にあり、Web 版も 5 画面が通しで動作している。

まとめ

MarpolBase を RDF 化することで、種特異的な植物ゲノムリソースを外部リソースと連動させることができた。またエンドポイントを TogoMCP と RDF Portal に登録することで、国内の共通基盤に植物ゲノムリソースを提供できた。他のリソースにも当てはまる教訓は、表 2 とそれに続く節に書いたとおりである。すなわち、主要な横断参照ハブが索引していない生物種を扱うリソースの場合、統合の接点は遺伝子 ID ではなく、そのリソースが自ら付与することを選んだ共通語彙 — 本件では何より 独自の KO 付与 — である。

DDBJ 側については、DFAST-Agent と MARKit はいずれも登録作業の手作業を減らすものだが、前提とする条件が異なる。DFAST-Agent は必要な情報を対話で集めるため能力の高いエージェントに依存するのに対し、MARKit は配列から導ける部分は自動で決め、本当に判断が必要な箇所だけを提出者に尋ねる。local LLM での試みは、対話型のアプローチが現時点ではフロンティアモデル無しには再現しにくいことを示しており、決定的な経路を並行して保つことの根拠になっている。

参考文献

- Tanizawa Y, Mochizuki T, Yagura M, Sakamoto M, Fujisawa T, Kawamura S, Shimokawa E, Yamaoka S, Nishihama R, Bowman JL, Berger F, Yamato KT, Kohchi T, Nakamura Y. MarpolBase: genome database for *Marchantia polymorpha* featuring high quality reference genome sequences. *Plant and Cell Physiology* 2025;67(3):377-388. <https://doi.org/10.1093/pcp/pcaf159>
- Bowman JL, Kohchi T, Yamato KT, et al. Insights into Land Plant Evolution Garnered from the *Marchantia polymorpha* Genome. *Cell* 2017;171(2):287-304.e15. <https://doi.org/10.1016/j.cell.2017.09.030>
- Tanizawa Y, Fujisawa T, Nakamura Y. DFAST: a flexible prokaryotic genome annotation pipeline for faster genome publication. *Bioinformatics* 2018;34(6):1037-1039. <https://doi.org/10.1093/bioinformatics/btx713>
- Ikeda S, Ono H, Ohta T, et al. TogoID: an exploratory ID converter to bridge biological datasets. *Bioinformatics* 2022;38(17):4194-4199. <https://doi.org/10.1093/bioinformatics/btac491>

謝辞

DBCLS BioHackathon 2026 の主催者、および議論いただいた参加者の皆様に感謝する。本研究では DBCLS が維持する TogoMCP と RDF Portal を利用した。